


BERT: Conceitos Fundamentais e Aplicações

Bidirectional Encoder Representations from Transformers



Encoder

Decoder

Decoder-only

Encoder-only

- 🕒 Desenvolvido pelo **Google** em 2018
- 🏗️ Baseado na arquitetura **Transformer**
- 📈 Um dos primeiros **LLMs** de sucesso
- 💡 Revolucionou o **Processamento de Linguagem Natural**

#Illustrative example, exact model architecture may vary slightly

Arquitetura do Transformer


A base para modelos de linguagem modernos como o BERT

Visão Geral

- ✓ Introduzido em 2017 no artigo "Attention is All You Need"
- ✓ Arquitetura **codificador-decodificador**
- ✓ Totalmente baseado em **mecanismos de atenção**
- ✓ Processamento **paralelo** (não sequencial)

Mecanismo de Atenção


- ✓ Permite ao modelo **focar em partes relevantes** da entrada
- ✓ Calcula **pesos de atenção** para cada elemento
- ✓ Resolve o problema de **longas dependências**



Comparação entre arquiteturas Transformer, GPT e BERT

Autoatenção Multi-cabeça

- ✓ Permite ao modelo focar em **diferentes posições**
- ✓ Múltiplas **cabeças de atenção** em paralelo
- ✓ Cada cabeça aprende **relações contextuais** diferentes



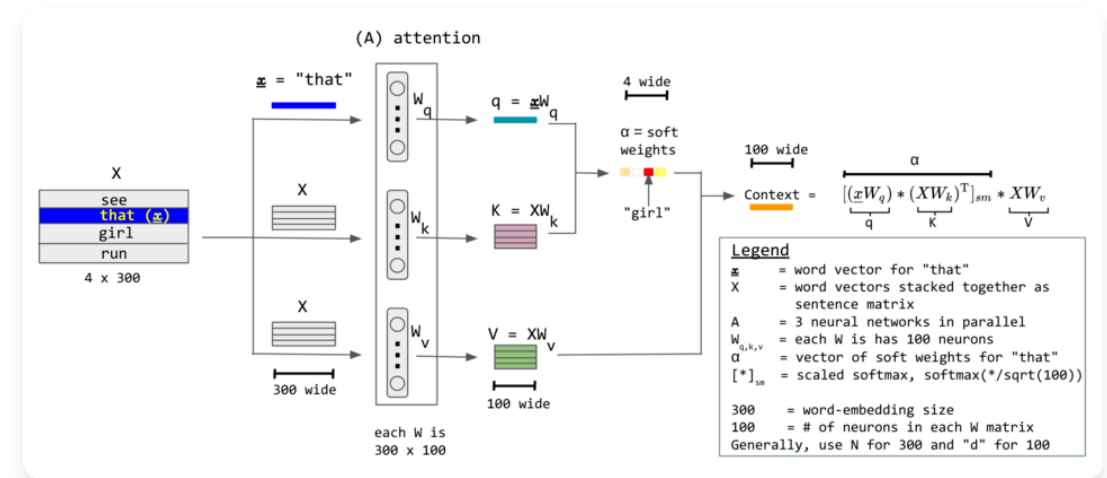
Estrutura do codificador do Transformer com mecanismo de autoatenção

Racional por Trás do Mecanismo de Atenção

Por que o mecanismo de atenção revolucionou o Processamento de Linguagem Natural

🧠 Intuição do Conceito

- ✓ Baseado na capacidade humana de **focar em informações relevantes**
- ✓ Permite ao modelo **ponderar a importância** de diferentes partes da entrada
- ✓ Cria **conexões diretas** entre quaisquer posições da sequência



➡ Vantagens sobre RNNs

RNNs

- ✗ Processamento **sequencial**
- ✗ **Dificuldade** com longas dependências
- ✗ **Esquecimento** de informações iniciais

Atenção

- ✓ Processamento **paralelo**
- ✓ **Conexões diretas** entre quaisquer tokens
- ✓ **Manutenção** de informações relevantes

Visualização do mecanismo de atenção focando em palavras relevantes

💡 Resolvendo Problemas Fundamentais

- ✓ **Dependências de longo alcance**: conecta palavras distantes
- ✓ **Bottleneck de informação**: permite acesso direto a todas as posições
- ✓ **Paralelização**: processamento simultâneo de toda a sequência

💡 Analogia com a Atenção Humana

Ao ler uma frase complexa, nossa atenção naturalmente se concentra nas palavras mais importantes para entender o contexto. O mecanismo de atenção imita esse comportamento, "olhando" para todas as palavras simultaneamente e decidindo quais são mais relevantes para a compreensão atual.

- ★ Resultado: modelos com **melhor compreensão contextual** e capacidade de capturar relações complexas entre palavras

Mecanismo de Atenção

O coração da arquitetura Transformer e do BERT

🧠 Importância do Mecanismo


- ✓ Permite ao modelo **focar em partes relevantes** da entrada
- ✓ Resolve o problema de **longas dependências** em sequências
- ✓ Permite **processamento paralelo** (diferente de RNNs)

Σ Fundamentos Matemáticos

- ✓ Baseado em três componentes: **Query (Q)**, **Key (K)** e **Value (V)**
- ✓ Cada palavra na sequência gera seus próprios Q, K e V

$$\text{Attention}(Q, K, V) = \text{softmax}(QK^T/\sqrt{d_k})V$$

Scaled Dot-Product Attention



Cálculo de pesos de atenção usando scaled dot-product

🔗 Processo Passo a Passo

1

Cálculo de Scores

Produto escalar entre Q e K de cada palavra

2

Normalização

Aplicação de softmax para obter pesos


3

Combinação

Soma ponderada dos valores V

- ✓ **Autoatenção multi-cabeça** permite capturar diferentes tipos de relações
- ✓ Cada cabeça aprende **padrões contextuais diferentes**

Multi-Head Attention



Estrutura do mecanismo de autoatenção multi-cabeça

Modelagem de Linguagem Mascarada (MLM)

A principal inovação do treinamento do BERT

💡 Importância do MLM

- ✓ Permite **aprendizado bidirecional** do contexto
- ✓ Captura **relações contextuais** entre palavras
- ✓ Diferencia o BERT de modelos **unidirecionais** (ex: GPT)


🔗 Como Funciona

- ✓ **15%** dos tokens são mascarados com [MASK]
- ✓ Objetivo: **prever a palavra original** mascarada
- ✓ Modelo usa **contexto bilateral** para fazer previsão

Exemplo Prático:


O gato está sentado no [MASK]

Previsão: "sofá" (com base no contexto bilateral)




Exemplo de BERT prevendo palavra mascarada (MLM)

🔗 Processo de Mascaramento



- ✓ Estratégia de **mascaramento variável** evita viés
- ✓ Força o modelo a **aprender representações robustas**




Diferença entre Modelagem de Linguagem (LM) e Modelagem de Linguagem Mascarada (MLM)

Como o BERT Funciona

Arquitetura específica e processamento de texto

Arquitetura Específica

- ✓ Baseado **apenas no codificador** do Transformer
- ✓ Dois tamanhos: **BERT-base** (110M parâmetros) e **BERT-large** (340M parâmetros)
- ✓ Processamento **bidirecional** do texto
- ✓ Múltiplas camadas de **autoatenção multi-cabeça**




Comparação entre arquiteturas BERT e OpenAI GPT

Codificação Posicional

- ✓ Informa a **posição** de cada token na sequência
- ✓ Usa **funções seno e cosseno** para gerar vetores posicionais
- ✓ Adicionada aos **embeddings de entrada**

Processamento de Texto

- ✓ **Tokenização** usando WordPiece
- ✓ Conversão de tokens em **vetores de embedding**
- ✓ Adição de **tokens especiais** ([CLS], [SEP])



Processamento de duas sentenças pelo BERT com saída de classificação

Treinamento do BERT


Pré-treinamento e tarefas fundamentais

🎓 Pré-treinamento

- ✓ **4 dias** de treinamento contínuo
- ✓ Usando **TPUs** (Tensor Processing Units)
- ✓ Conjuntos de dados: **Wikipedia** (2.5B palavras) e **BooksCorpus** (800M palavras)
- ✓ Aprendizado de **representações linguísticas** gerais

🔗 Modelagem de Linguagem Mascarada (MLM)


- ✓ **15%** dos tokens são mascarados com [MASK]
- ✓ Objetivo: **prever a palavra original** mascarada
- ✓ Permite **aprendizado bidirecional** do contexto



Fluxo de pré-treinamento e fine-tuning do BERT

→ Previsão de Próxima Sentença (NSP)

- ✓ Duas sentenças: **A** e **B**
- ✓ 50% das vezes: **B é a próxima sentença** após A
- ✓ 50% das vezes: **B é uma sentença aleatória**
- ✓ Objetivo: prever se **B segue A** no texto original



Diferença entre Modelagem de Linguagem (LM) e Modelagem de Linguagem Mascarada (MLM)

Fine-tuning do BERT

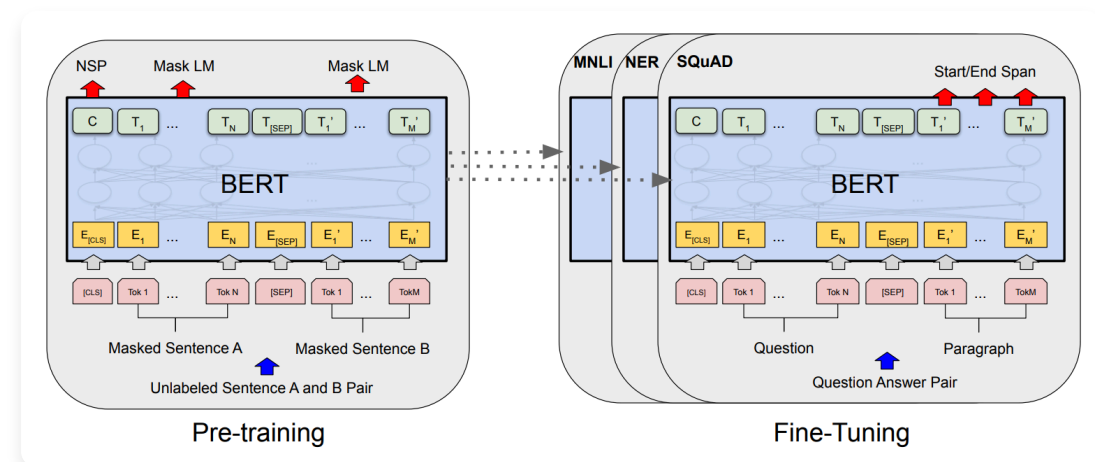
Adaptação para tarefas específicas

Processo de Fine-tuning

- ✓ Utiliza modelo **pré-treinado** como ponto de partida
- ✓ Adiciona **camada de saída** específica para a tarefa
- ✓ Treinamento com **conjunto de dados menor** e específico
- ✓ Ajuste **seletivo de parâmetros** (pode ser total ou parcial)

Vantagens do Fine-tuning


- ✓ **Economia de tempo** e recursos computacionais
- ✓ Necessidade de **menos dados** para treinamento
- ✓ **Alto desempenho** mesmo com domínios específicos
- ✓ Aproveita **conhecimento geral** do pré-treinamento



Fluxo de pré-treinamento e fine-tuning do BERT

Exemplos de Aplicações

- ✓ **Classificação de texto**: análise de sentimento, classificação de tópicos
- ✓ **Reconhecimento de entidades**: identificação de pessoas, locais, organizações
- ✓ **Resposta a perguntas**: sistemas de QA baseados em contexto
- ✓ **Similaridade de sentenças**: comparação semântica entre textos



Exemplo de adaptação do BERT para tarefa de classificação

Aplicações do BERT


Utilização prática em tarefas de Processamento de Linguagem Natural

📊 Classificação de Texto

- ✓ **Análise de sentimento** em avaliações e redes sociais
- ✓ **Classificação de tópicos** em documentos
- ✓ **Detecção de spam** em e-mails e comentários

🔍 Reconhecimento de Entidades

- ✓ Identificação de **pessoas**, **locais** e **organizações**
- ✓ Extração de **informações estruturadas** de texto
- ✓ Aplicações em **busca semântica**



Exemplo de BERT prevendo palavra mascarada (MLM)

🗨️ Resposta a Perguntas

- ✓ Sistemas de **QA baseados em contexto**
- ✓ **Chatbots** e assistentes virtuais
- ✓ Extração de **respostas específicas** de documentos

... Outras Aplicações

- ✓ **Tradução automática** de idiomas
- ✓ **Sumarização** de textos longos
- ✓ **Geração de texto** e completamento

Variantes do BERT

Evoluções e adaptações do modelo original


BERT Multilíngue

- ✓ Treinado em **104 idiomas**
- ✓ Vocabulário **compartilhado** entre idiomas
- ✓ Capacidade de **transferência cruzada** entre línguas

RoBERTa

- ✓ **Versão otimizada** do BERT
- ✓ Treinado com **mais dados** e por mais tempo
- ✓ Remove **NSP** (Next Sentence Prediction)
- ✓ **Batch sizes maiores** e taxas de aprendizado dinâmicas

BERT Size & Architecture



Comparação de tamanhos e arquiteturas do BERT

DistilBERT

- ✓ **Versão compacta** do BERT
- ✓ **40% menor** e 60% mais rápido
- ✓ Mantém **97% do desempenho** do BERT

... Outras Variantes

- ✓ **ALBERT**: redução de parâmetros via compartilhamento
- ✓ **CamemBERT**: versão para língua francesa
- ✓ **BioBERT**: especializado em textos médicos

Conclusão


Impacto do BERT e futuro dos modelos de linguagem

Impacto do BERT

- ✓ **Revolucionou** o Processamento de Linguagem Natural
- ✓ Estabeleceu **novas linhas de base** em tarefas de PLN
- ✓ Demonstrou o poder do **pré-treinamento** em grandes conjuntos de dados
- ✓ Popularizou a arquitetura **Transformer**

Contribuições Principais

- ✓ **Aprendizado bidirecional** de representações contextuais
- ✓ **Modelagem de Linguagem Mascarada** (MLM)
- ✓ Abordagem de **pré-treinamento + fine-tuning**



Evolução dos modelos de linguagem: do pré-treinamento ao fine-tuning

Futuro dos Modelos de Linguagem

- ✓ Modelos **maiores e mais capazes**
- ✓ Arquiteturas mais **eficientes** e sustentáveis
- ✓ Modelos **especializados** para domínios específicos
- ✓ Maior **acessibilidade** e democratização da tecnologia

"O BERT não foi apenas um modelo, mas um marco que redefiniu o que é possível em Processamento de Linguagem Natural."

— Comunidade de PLN